

**Educação
Profissional
Paulista**

Técnico em
**Ciência de
Dados**

Introdução à Ciência de Dados, Ferramentas e Jargões da Área

Termos técnicos na Ciência de Dados

Aula 2

Código da aula: [DADOS]ANO1C1B1S2A2

Exposição



Objetivos da Aula

- Conhecer os termos técnicos utilizados na área de Ciência de Dados e Inteligência Artificial.




Competências da Unidade (Técnicas e Socioemocionais)

- Comunicar ideias de forma clara e assertiva, sabendo ouvir ativamente, visando à construção de relacionamentos sólidos.
- Colaborar efetivamente com outros profissionais, como cientistas de dados e engenheiros de dados.
- Trabalhar em equipe, compartilhando conhecimentos, contribuindo com ideias e colaborando para alcançar objetivos comuns.



Recursos Didáticos

- Recurso audiovisual para exibição de vídeos e imagens.
- Acesso ao laboratório de informática e/ou internet.



Duração da Aula

50 minutos

Cronograma da aula de hoje

Termos técnicos na Ciência de Dados

- ✓ Introdução e revisão de vocabulário técnico.
- ✓ Exemplos de seus significados.
- ✓ Atividade.

Exposição

Momento de revisão!

Em grupos e com a ajuda do(a) professor(a), faça uma revisão da aula passada.


- ✓ Quais foram os principais tópicos vistos?
- ✓ Você se lembra dos exemplos dados?
- ✓ Fale sobre o que aprendeu para os seus colegas.

Exposição


Classificação

A **classificação** é um conceito fundamental para a **Ciência de Dados e aprendizado de máquina**, usada para prever a categoria ou classe de um determinado objeto ou amostra com base em suas características.

Dentro de aprendizado de máquina, existem algoritmos de **classificação supervisionados e não supervisionados**. Em um cenário supervisionado, o **algoritmo é treinado com um conjunto de dados rotulado**, em que as classes já são conhecidas. Em um cenário **não supervisionado**, o **algoritmo é apresentado a dados não rotulados e deve deduzir a estrutura dos dados** para determinar as classes.



Exposição



© Getty Images

Algoritmos de aprendizado de máquina

Algoritmos de aprendizado de máquina são um conjunto de métodos que um computador usa para executar tarefas **específicas** sem ser explicitamente programado para isso. Alguns exemplos incluem:

Árvores de Decisão

Usadas para tarefas de classificação e regressão, elas criam um modelo que prevê a variável-alvo com base em **várias decisões de entrada**. Imagine um serviço de streaming que usa uma árvore de decisão para sugerir programas aos usuários. **As decisões podem ser baseadas em parâmetros como “O usuário assistiu ao programa X?” ou “O usuário gosta de programas de comédia?”.**



O algoritmo de Árvore de Decisão



© Getty Images

Exposição



Fonte: <https://www.youtube.com/watch?v=asyLr0NUf3Q>.

Exposição

Algoritmos de aprendizado de máquina

- ***K-Nearest Neighbors (KNN)***: Um algoritmo de classificação em que a previsão para uma nova observação é baseada na proximidade com as observações existentes.
- ***Naive Bayes***: Algoritmo de classificação baseado no teorema de Bayes, com uma suposição de independência entre os preditores.
- ***Redes Neurais Artificiais (ANN)***: Esse tipo de algoritmo é inspirado no funcionamento do cérebro humano e consiste em um grande número de neurônios artificiais interconectados. Cada neurônio recebe entrada de vários outros neurônios, e a saída é determinada por uma função de ativação.



© Getty Images

Exposição



© Getty Images

Algoritmos de aprendizado de máquina

- **Máquinas de Vetores de Suporte (SVM):** São algoritmos de aprendizado de máquina usados principalmente para problemas de classificação, mas também podem ser usados para problemas de regressão. As SVMs funcionam encontrando o hiperplano que maximiza a margem entre as classes no espaço de características.
- **Random Forest** (Floresta Aleatória): Esse é um método de aprendizado de máquina para classificação, regressão e outras tarefas que operam pela construção de uma infinidade de árvores de decisão no momento do treinamento e produzem a classe que é o modo das classes (classificação) ou a previsão média (regressão) das árvores individuais.

Fonte: STACK, 2020.

Exposição



© Getty Images

Algoritmos de aprendizado de máquina

- **Algoritmos de Boosting (Impulsionamento):** Boosting é um método de aprendizado de máquina que se baseia na ideia de criar regras de previsão robustas por meio de uma combinação de regras de previsão fracas e relativamente simples. **O Boosting é usado para reduzir o viés e a variância em aprendizado supervisionado.** Alguns dos algoritmos de Boosting mais populares são o **AdaBoost**, o **Gradient Boosting** e o **XGBoost**. Eles geralmente são usados em problemas de classificação e regressão.

Visão computacional

Visão computacional é um campo que envolve obtenção, processamento e análise de dados visuais, ou seja, imagens ou vídeos. A visão computacional **é usada para garantir que os computadores “vejam” e entendam o conteúdo das imagens digitais ou vídeos.**

Os algoritmos de **visão computacional podem ser usados para várias tarefas, como detecção de objetos** (localizando e identificando objetos em imagens ou vídeos), **reconhecimento facial, rastreamento de objetos** (seguindo objetos à medida que se movem em um vídeo) e até mesmo **geração de imagens por meio de redes geradoras adversariais (GANs).**



Exemplo

Um exemplo de uso de visão computacional seria o Facebook, reconhecendo e sugerindo tags para rostos em fotos, ou carros autônomos, identificando objetos, pessoas e sinais de trânsito ao seu redor.

Regressão

A regressão é uma técnica estatística usada para entender a relação entre variáveis dependentes e independentes.

Em Ciência de Dados, geralmente é usada para prever uma saída contínua.

Regressão linear

Esse modelo assume uma relação linear entre as variáveis de entrada e a variável de saída. Pode ser usado para prever vendas futuras com base em vendas passadas.

$$y = a + bx + e_r$$

onde:

- y é a variável dependente.
- x é a variável independente.
- a é a interceptação do eixo Y.
- b é a inclinação da linha (também conhecida como coeficiente de regressão).
- e_r é o erro (diferença entre o valor previsto e o valor real).

Regressão linear múltipla


A regressão linear múltipla é uma extensão da regressão linear simples que possibilita a inclusão de duas ou mais variáveis independentes. A equação de uma regressão linear múltipla é:

$$y = a + b_1x_1 + b_2x_2 + \cdots b_nx_n + e_r$$

onde:

- y é a variável dependente.
- x_1, x_2, x_n são as variáveis independentes.
- a é a interceptação do eixo y .
- b_1, b_2, b_n são os coeficientes de regressão das respectivas variáveis independentes.
- e_r é o erro (diferença entre o valor previsto e o valor real).

Exposição



© Getty Images

Clustering (agrupamento)

Clustering, ou agrupamento, é uma técnica de aprendizado de máquina não supervisionada que envolve a divisão de um conjunto de dados em grupos, ou clusters, de modo que os dados em um mesmo cluster sejam mais semelhantes entre si do que os dados em outros clusters.

A semelhança é quantificada de acordo com uma medida específica, como a distância euclidiana, a correlação etc.

Algumas das técnicas de clustering mais comuns são:

K-Means Clustering (K-Médias): Essa é provavelmente a técnica mais conhecida de clustering. O algoritmo *K-Means* começa selecionando K pontos no espaço de dados como centros de clusters iniciais.

Hierarchical Clustering (Agrupamento Hierárquico): O agrupamento hierárquico constrói uma hierarquia de clusters, o que é útil para entender a estrutura dos dados em diferentes níveis de granularidade.

Algumas das técnicas de *clustering* mais comuns são:

- ***Density-Based Clustering (Agrupamento Baseado em Densidade)***: O agrupamento baseado em densidade considera clusters como áreas de alta densidade separadas por áreas de baixa densidade.
- ***Model-Based Clustering (Agrupamento Baseado em Modelos)***: Nesse tipo de clustering, um modelo é hipoteticamente ajustado aos dados. Cada cluster segue um determinado modelo probabilístico. Uma abordagem comum é a mistura de modelos Gaussianos, em que se assume que cada cluster segue uma distribuição Gaussiana (normal).



Resumo da aula de hoje!

- Em duplas, **façam um resumo dos principais tópicos e das ideias** novas que vocês aprenderam na aula de hoje.
- Separem os temas em tópicos e, com suas palavras, **escrevam o que vocês entenderam sobre eles**.
- Esse resumo deve **ser enviado pelo AVA** – Ambiente Virtual de Aprendizagem.



© Pexels

Momento
de **reflexão**



Vamos
fazer uma
atividade

Produção de texto reflexivo

O texto deve ter entre 250 e 500 caracteres com espaços (equivalente a 5 ou 10 linhas).

 **10 minutos**

 **Em grupo**



Pense profundamente sobre o tema e as questões apresentadas. Permita-se ter um tempo para refletir antes de começar a escrever.



Seu texto deve expressar **seu próprio pensamento e perspectiva**. Evite repetir opiniões e ideias de outras pessoas.



Estruture seu texto de **maneira clara e lógica**. Comece com uma introdução sobre o tema, seguida de suas reflexões, e conclua com uma ideia final.



Use **linguagem clara e compreensível**. Antes de entregar o texto, revise-o para garantir correção gramatical, clareza e coerência de ideias.



O que nós
aprendemos
hoje?

Hoje desenvolvemos:

- 1** Capacidade de **compreender o vocabulário técnico da área** de Ciência de Dados.
- 2** Habilidades para definir e aplicar o **Aprendizado de Máquina (Machine Learning)** em nossas rotinas de trabalho e como são aplicadas no nosso dia a dia.
- 3** Uma visão geral sobre os principais **algoritmos do aprendizado de máquina**.

© Getty Images

Saiba mais

Para todos os conceitos vistos em aula, há um aprofundamento nos vídeos selecionados abaixo.

HASHTAG PROGRAMAÇÃO. A Árvore de Decisão – Algoritmos de Aprendizado de Máquinas. Disponível em:

<https://www.youtube.com/watch?v=aNrdgC0lIZ8>. Acesso em: 9 jan. 2024.

STACK. Entenda o Algoritmo de Machine Learning Random Forest, 2020.

Disponível em: <https://www.youtube.com/watch?v=jBGxiu8Kllo&t=2s>.

Acesso em: 9 jan. 2024.

Para saber mais sobre os tipos de algoritmos de Aprendizado de Máquina, você pode acessar o perfil da Univesp no YouTube:

UNIVESP. Aprendizado de Máquinas. Disponível em:

<https://www.youtube.com/@univesptv/Search>. Acesso em: 9 jan. 2024.

É importante que você assista aos vídeos e utilize esse tempo para aprimorar seu vocabulário técnico sobre a área.

Referências da aula

AMARAL, Fernando. **Introdução à Ciência de Dados: mineração de dados e *Big Data***. Rio de Janeiro: Alta Books, 2018.

INTELIGÊNCIA ARTIFICIAL NA SAÚDE. **O algoritmo de Árvore de Decisão**. Disponível em: <https://www.youtube.com/watch?v=asyLr0NUf3Q>. Acesso em: 9 jan. 2024.

STACK. **Entenda o Algoritmo de Machine Learning Random Forest**, 2020. Disponível em: <https://www.youtube.com/watch?v=jBGxiu8Kllo&t=2s>. Acesso em: 9 jan. 2024.

Identidade visual: imagens © Getty Images.

**Educação
Profissional
Paulista**

Técnico em
**Ciência de
Dados**