

**Educação
Profissional
Paulista**

Técnico em
**Ciência de
Dados**

História e evolução da Ciência de Dados

Desenvolvimento de técnicas e ferramentas de análise de dados

Aula 2

Código da aula: [DADOS]ANO1C1B1S5A2

Exposição



Objetivo da aula

Conhecer as principais tendências da Ciência de Dados e vislumbrar possíveis cenários futuros.




Competências da Unidade (técnicas e socioemocionais)

- Comunicar ideias de forma clara e assertiva, sabendo ouvir ativamente, visando à construção de relacionamentos sólidos;
- Colaborar efetivamente com outros profissionais, como cientistas de dados e engenheiros de dados;
- Trabalhar em equipe, compartilhando conhecimentos, contribuindo com ideias e colaborando para alcançar objetivos comuns.



Recursos didáticos

- Recurso audiovisual para exibição de vídeos e imagens.
- Acesso ao laboratório de informática e/ou à internet.



Duração da aula

50 minutos.

Exposição

Revisão

Em grupos, façam uma revisão do conteúdo visto na aula passada.

Quais as principais informações discutidas sobre:

- ✓ Contexto histórico da evolução da análise de dados;
- ✓ Análise descritiva e exemplos;
- ✓ Análise inferencial e exemplos.

Introdução à análise de dados

A análise de dados é o processo de **inspecionar, limpar, transformar** e **modelar** dados com o objetivo de descobrir informações úteis, sugerir conclusões e apoiar a tomada de decisão.

Com a geração e o armazenamento crescente de dados em todos os setores, a análise de dados tornou-se uma parte essencial para ajudar as empresas a tomar decisões com base em dados.


Pode abranger uma variedade de técnicas e métodos, desde a simples **análise descritiva** até os **modelos estatísticos** e de **machine learning** (aprendizado de máquina) complexos.

Tipos de dados: quantitativos e qualitativos

Os dados **quantitativos** são numéricos e são usados para quantificar a magnitude de uma variável. Eles podem ser **discretos** (exemplo: número de vendas) ou **contínuos** (exemplo: peso).

Já os dados **qualitativos**, ou categóricos, são usados para classificar ou rotular características, e não têm uma ordem ou medida inerente. Eles podem ser **nominais** (exemplo: cor dos olhos) ou **ordinais** (exemplo: classificação de um produto).

Resumo



Fonte: MORETTIN, 2017.

Entendendo melhor: dados qualitativos

Algumas variáveis, como sexo, educação, estado civil, apresentam como possíveis realizações uma qualidade (ou atributo) do indivíduo pesquisado.

Dentre as variáveis qualitativas, ainda podemos fazer uma distinção entre dois tipos:

- **Variável qualitativa nominal**, para a qual não existe nenhuma ordenação nas possíveis realizações.
- **Variável qualitativa ordinal**, para a qual existe uma ordem nos resultados.

Exposição

Entendendo melhor: dados qualitativos

Variável qualitativa ordinal

Nº	Estado civil	Grau de instrução	Nº de filhos	Salário (x sal. mín.)	Idade		Região de procedência
					Anos	Meses	
1	solteiro	Ensino Fundamental	0	4,00	26	3	interior
2	casado	Ensino Fundamental	1	4,56	32	10	capital
3	casado	Ensino Fundamental	2	5,25	36	5	capital
4	solteiro	Ensino Médio	0	5,73	20	10	outra
5	solteiro	Ensino Fundamental	0	6,26	40	7	outra
6	casado	Ensino Fundamental	0	6,66	25	0	interior
7	solteiro	Ensino Fundamental	0	6,86	41	0	interior
8	solteiro	Ensino Fundamental	0	7,39	43	4	capital
9	casado	Ensino Médio	1	7,59	34	10	capital
10	solteiro	Ensino Médio	0	7,44	23	6	outra
11	casado	Ensino Médio	2	8,12	33	6	interior
12	solteiro	Ensino Fundamental	0	8,46	27	11	capital
13	solteiro	Ensino Médio	0	8,74	37	5	outra
14	casado	Ensino Fundamental	3	8,95	44	2	outra
15	casado	Ensino Médio	0	9,13	30	5	interior

Variável qualitativa nominal

Fonte: MORETTIN, 2017.

Entendendo melhor: dados qualitativos

Algumas variáveis, como número de filhos, salário, idade, apresentam como possíveis realizações números resultantes de uma contagem ou mensuração. De modo análogo, as variáveis quantitativas podem sofrer uma classificação dicotômica:

- **Variáveis quantitativas discretas**, cujos possíveis valores formam um conjunto finito ou enumerável de números e resultam, frequentemente, de uma contagem, como número de filhos (0, 1, 2...).
- **Variáveis quantitativas contínuas**, cujos possíveis valores pertencem a um intervalo de números reais e resultam de uma mensuração, por exemplo: estatura e massa de um indivíduo.

Exposição

Entendendo melhor: dados qualitativos

Variável
quantitativa
discreta

Nº	Estado civil	Grau de instrução	Nº de filhos	Salário (x sal. mín.)	Idade		Região de procedência
					Anos	Meses	
1	solteiro	Ensino Fundamental	0	4,00	26	3	interior
2	casado	Ensino Fundamental	1	4,56	32	10	capital
3	casado	Ensino Fundamental	2	5,25	36	5	capital
4	solteiro	Ensino Médio	0	5,73	20	10	outra
5	solteiro	Ensino Fundamental	0	6,26	40	7	outra
6	casado	Ensino Fundamental	0	6,66	25	0	interior
7	solteiro	Ensino Fundamental	0	6,86	41	0	interior
8	solteiro	Ensino Fundamental	0	7,39	43	4	capital
9	casado	Ensino Médio	1	7,59	34	10	capital
10	solteiro	Ensino Médio	0	7,44	23	6	outra
11	casado	Ensino Médio	2	8,12	33	6	interior
12	solteiro	Ensino Fundamental	0	8,46	27	11	capital
13	solteiro	Ensino Médio	0	8,74	37	5	outra
14	casado	Ensino Fundamental	3	8,95	44	2	outra
15	casado	Ensino Médio	0	9,13	30	5	interior

Variável
quantitativa
contínua

Fonte: MORETTIN, 2017.

Descrição e exploração de dados

A descrição de dados envolve o uso de **estatísticas descritivas** para resumir e descrever as características principais dos dados. Medidas de tendência central, como **média, mediana e moda**, são usadas para identificar valores típicos.

Medidas de dispersão, como **variância, desvio padrão e intervalo interquartil**, são usadas para descrever a variabilidade nos dados. Gráficos como **histogramas** e **boxplots** também são usados para visualizar essas estatísticas.

Média

A média aritmética é, talvez, a medida mais usada. Contudo, ela pode conduzir a erros de interpretação. Em muitas situações, a mediana é uma medida mais adequada. Voltaremos a este assunto mais adiante.

Vamos formalizar os conceitos introduzidos acima. Se $x_1, x_2, \dots, x_n$ são os n valores (distintos ou não) da variável X , a média aritmética, ou simplesmente média, de X pode ser escrita como:

$$\bar{x} = \frac{x_1 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

Mediana

É o valor que ocupa a **posição central** quando os dados estão ordenados.

Consideremos, agora, as observações ordenadas em ordem crescente. Vamos denotar a menor observação por $x_{(1)}$, a segunda por $x_{(2)}$, e assim por diante, obtendo:

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n-1)} \leq x_{(n)}$$

Por exemplo, se $x_1 = 3, x_2 = -2, x_3 = 6, x_4 = 1, x_5 = 3$, então:

$-2 \leq 1 \leq 3 \leq 3 \leq 6$, de modo que $x_{(1)} = -2, x_{(2)} = 1, x_{(3)} = 3, x_{(4)} = 3$ e $x_{(5)} = 6$.

Mediana

Estas observações ordenadas são chamadas **estatísticas de ordem**.

Com essa notação, a mediana da variável X pode ser definida como:

$$md(X) = \begin{cases} x_{\left(\frac{n+1}{2}\right)'} & \text{se } n \text{ ímpar;} \\ \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}, & \text{se } n \text{ par.} \end{cases}$$

Exposição

É o valor (ou valores) de **maior frequência** na amostra (Obs.: pouco usada na prática). Exemplo:

Moda

Aluno	Nota de prova
1	1,0
2	1,0
3	1,5
4	3,5
5	3,5
6	4,5
7	4,5
8	4,5
9	4,5
10	8,0
11	9,0
12	9,5
13	9,5
14	10,0
15	10,0

$$Mo = 4,5$$

Limpeza e preparação de dados

Antes de analisar os dados, é crucial **prepará-los** e **limpá-los**. Isso envolve **tratar dados ausentes e outliers, corrigir erros e inconsistências** e **transformar dados** para obter uma análise melhor.

A limpeza de dados é uma etapa crucial, porque a qualidade dos dados pode ter um grande impacto nos resultados da análise de dados. **Dados mal preparados podem levar a *insights* imprecisos ou enganosos.**



Recurso digital

UNIVESP. Mineração de Dados – Preparação e limpeza de dados. Disponível em: <https://www.youtube.com/watch?v=10kmcTfoxiM>. Acesso em: 29 jan. 2024.

Vamos
fazer uma
atividade

Média, mediana e moda

Dada a tabela abaixo, calcule a média, a mediana e a moda para os bônus recebidos pelos estagiários de uma empresa de tecnologia.

Detalhe todos os cálculos para a obtenção dos resultados.

Estagiário	Bônus A	Bônus B
1	R\$ 1.100,00	R\$ 1.100,00
2	R\$ 1.720,00	R\$ 1.700,00
3	R\$ 1.700,00	R\$ 1.700,00
4	R\$ 1.100,00	R\$ 1.100,00
5	R\$ 1.100,00	R\$ 1.700,00
6	R\$ 5.000,00	R\$ 24.000,00

Dados fictícios.
Elaborado especialmente para o curso.



© Getty Images

O que nós
**aprendemos
hoje?**

Hoje desenvolvemos:

- 1** A distinção entre os tipos de dados: qualitativos e quantitativos;
- 2** A definição dos conceitos de moda, mediana e média;
- 3** A execução de uma atividade prática de moda, mediana e média.



Saiba mais

Por que medidas de posição e dispersão são essenciais na Ciência de Dados? Mergulhe nesses conceitos e veja como eles moldam o mundo dos dados!

UNIVESP. Estatística e Probabilidade de dados – Medidas de posição e de dispersão.

Disponível em:

<https://www.youtube.com/watch?v=3EDqcdiMN38>.

Acesso em: 29 jan. 2024.

Referências da aula

MORETTIN, P, A.; BUSSAB, W. O. Estatística básica. São Paulo: Editora Saraiva Uni, 2017.

UNIVESP. Mineração de Dados – Preparação e limpeza de dados. Disponível em: <https://www.youtube.com/watch?v=10kmcTfoxiM>. Acesso em: 29 jan. 2024.

Identidade visual: Imagens © Getty Images

Educação Profissional Paulista

Técnico em
**Ciência de
Dados**