

Educação Profissional Paulista

Técnico em
**Ciência de
Dados**

Redes neurais

Overfitting e regularização

Aula 1: Introdução a *overfitting*

Código da aula: [DADOS]ANO2C4B2S8A1

Redes neurais

Mapa da unidade 1 componente 4

semana
10
Transfer learning

Redes neurais
recorrentes (RNNs)


semana
11

semana
9

*Convolutional neural
networks (CNNs)*

semana
8

Você está aqui!
*Overfitting e
regularização*



Redes neurais

Mapa da
unidade 1
componente 4

Você está aqui!

Overfitting e regularização

**Aula 1: Introdução a
*overfitting***

Código da aula: [DADOS]ANO2C4B2S8A1

8



Objetivos da aula

- Compreender o conceito de *overfitting* nas redes neurais.



Recursos didáticos

- Recurso audiovisual para exibição de vídeos e imagens.
- Acesso ao laboratório de informática e/ou à internet.
- Software Anaconda/Jupyter Notebook instalado ou similar.



Duração da aula

50 minutos.



Habilidades técnicas

- Utilizar os conceitos básicos de *overfitting* e regularização.



Habilidades socioemocionais

- Demonstrar interesse e curiosidade pelo conceito de *overfitting* e regularização.

Ponto de partida

Estudar só pela prova passada?

Imagine que você vai fazer uma prova de Matemática, mas, em vez de estudar os conceitos gerais, você decide estudar **apenas** as perguntas da **prova do ano anterior**. Você passa dias e noites decorando todas as respostas específicas daquela prova antiga.

No dia da sua prova atual, você percebe que as questões são **diferentes!** Mesmo que você tenha ido muito bem na prova antiga, o que você estudou não te ajudou tanto na prova nova, porque você focou demais os detalhes da prova passada.

Isso é como o **overfitting**: você ficou tão concentrado em acertar aquelas perguntas específicas que **não se preparou bem para novas situações**.

- ▶ Afinal, estudar apenas com as perguntas da prova passada (*overfitting*) é bom ou ruim?




Overfitting vs. underfitting

Assista ao vídeo e confira!


© Getty Images

Colocando
em **prática**




Produzido pela SEDUC-SP. Overfitting vs. underfitting. Youtube. Educação Profissional Paulista. Disponível em:
<https://youtu.be/ZT0VqQDBNUI?si=erLuRnB-U0eb5gVp>.

Causas do *overfitting*




Modelo muito complexo

Modelos com muitas camadas ou neurônios "memorizam" os dados em vez de aprender padrões úteis.




Falta de regularização

Sem penalizações, como L1, L2 ou *dropout*, o modelo se ajusta demais aos dados de treinamento.




Poucos dados

Uma quantidade limitada de dados dificulta a captura de padrões gerais, levando o modelo a se ajustar ao ruído.



Desequilíbrio de dados

Dados desbalanceados levam o modelo a focar as classes majoritárias, comprometendo sua generalização.



Muitas épocas de treinamento

Treinar por tempo excessivo faz o modelo aprender padrões específicos e irrelevantes do conjunto de dados.




Ausência de validação cruzada

Não dividir o conjunto de dados em partes, para validar o modelo durante o treinamento, aumenta o risco de *overfitting*.

Colocando
em **prática**

Definição de *overfitting*

- ▶ A rede aprende muitos padrões específicos do conjunto de treinamento, incluindo ruídos, resultando em mau desempenho em novos dados (validação).



Fonte: HOLBROOK; COOK, [s.d.], tradução nossa.
Produzido pela SEDUC-SP..

Colocando
em **prática**

Impacto do *overfitting* no desempenho dos modelos



Baixo desempenho em novos dados

O modelo acerta no treinamento, mas erra em novos dados, resultando em baixa acurácia.



Modelo não confiável

O modelo se torna instável e muda drasticamente com pequenos ruídos nos dados.



Aumento da variância

O modelo não funciona bem em produção, pois depende demais dos dados de treino.


Colocando
em **prática**

Acurácia

- ▶ É uma medida de desempenho que indica a proporção de previsões corretas feitas por um modelo em relação ao total de previsões realizadas.
- ▶ Em outras palavras, é a taxa de acertos de um modelo ou sistema, representando o quão bem ele consegue classificar ou identificar corretamente os exemplos dentro de um conjunto de dados.
- ▶ Em termos simples, acurácia responde à pergunta: "Quantas vezes o modelo acertou em relação ao total de tentativas?"

Colocando
em **prática**

Overfitting na classificação de pinguins



Materiais necessários

- Acesso ao laboratório de informática e/ou à internet.
- Software Anaconda/Jupyter Notebook instalado ou similar.



Passo a passo


1. Abra o roteiro da atividade prática e siga o passo a passo.
2. Use o material de apoio Notebook [DADOS]ANO2C4B2S8A1.ipynb para realizar a tarefa proposta.
3. Adicione os conceitos mais importantes à sua folha de dicas e consulte o material de referência do conjunto de dados para informações detalhadas.



20 minutos



Em grupo



Baixe o roteiro desta atividade / Baixe o material de apoio desta atividade



Pause e
responda

Qual dos seguintes fatores pode causar *overfitting* em um modelo?

Modelo simples com poucas camadas e neurônios.

Uso de técnicas de regularização como L1 e L2.

Modelo treinado por muitas épocas sem interrupção.

Dados balanceados que representam bem as diferentes classes.



Pause e
responda

Qual dos seguintes fatores pode causar *overfitting* em um modelo?



Modelo simples com poucas camadas e neurônios.

Uso de técnicas de regularização como L1 e L2.



Modelo treinado por muitas épocas sem interrupção.

Dados balanceados que representam bem as diferentes classes.





Pause e
responda

Qual é o impacto do *overfitting* no desempenho do modelo?

Apresenta um ótimo desempenho nos dados de treinamento e validação.

Aumento da variância, torna-se instável e muda com pequenos ruídos nos dados.

Mantém um desempenho consistente, independentemente dos dados de entrada.

Fica mais confiável em produção, pois aprendeu detalhes específicos.



Pause e
responda

Qual é o impacto do *overfitting* no desempenho do modelo?



Apresenta um ótimo desempenho nos dados de treinamento e validação.



Mantém um desempenho consistente, independentemente dos dados de entrada.

Aumento da variância, torna-se instável e muda com pequenos ruídos nos dados.



Fica mais confiável em produção, pois aprendeu detalhes específicos.





© Getty Images

O que nós
**aprendemos
hoje?**

Então ficamos assim...

- 1** O *overfitting* (sobreajuste) ocorre quando o modelo aprende padrões específicos dos dados de treino, incluindo ruídos. E o impacto do sobreajuste é o baixo desempenho em novos dados, pois o modelo não generaliza bem.
- 2** Além disso, o aumento da variância e um modelo pouco confiável em produção, pois depende muito dos dados de treinamento. As causas do *overfitting* incluem: a complexidade do modelo, falta de regularização, poucos dados ou dados desbalanceados e a ausência de validação cruzada.
- 3** Com relação ao tamanho ideal para minimizar os riscos em um dataset de treinamento, não há um número fixo universal, todavia uma regra prática é: de 10 a 100 vezes o número de parâmetros do modelo.

Saiba mais

Se você deseja se aprofundar no conceito de *overfitting* (sobreajuste) e evitar que seus modelos de *machine learning* se tornem complexos e não generalizem bem, este artigo é ideal.

GOOGLE FOR DEVELOPERS. Conceitos de ML: Overfitting. **Google**, 2024. Disponível em: <https://developers.google.com/machine-learning/crash-course/overfitting/overfitting?hl=pt-br>. Acesso em: 22 nov. 2024.

Referências da aula

Identidade visual: imagens © Getty Images

GÉRON, A. **Mãos à obra**: aprendizado de máquina com Scikit-Learn, Keras e TensorFlow: conceitos, ferramentas e técnicas para a construção de sistemas inteligentes. Rio de Janeiro: Alta Books, 2021.

GOOGLE FOR DEVELOPERS. Conceitos de ML: Overfitting. **Google**, 2024. Disponível em: <https://developers.google.com/machine-learning/crash-course/overfitting/overfitting?hl=pt-br>. Acesso em: 22 nov. 2024.

HOLBROOK, R.; COOK, A. Overfitting and underfitting. **Kaggle**, [s.d.]. Disponível em: <https://www.kaggle.com/code/ryanholbrook/overfitting-and-underfitting/tutorial>. Acesso em: 4 nov. 2024.

TOOR, U. N. The first, and the most frustrating, trap of Machine Learning – Overfitting!. **Medium**, 18 maio 2023. Disponível em: <https://medium.com/@usamanaeemtoor/the-first-and-the-most-frustrating-trap-of-machine-learning-overfitting-534678474ad0>. Acesso em: 22 nov. 2024.

Orientações ao professor

Slide 6



Orientações: a seção **Ponto de partida** aparece no início de cada aula e tem como objetivos ativar o conhecimento prévio dos estudantes sobre o tema da aula e estimular seu pensamento crítico e suas habilidades comunicativas. Por meio de uma situação-problema ou de um exemplo próximo da realidade dos estudantes, pretende-se sair da abstração conceitual e promover um diálogo dinâmico para explorar hipóteses, soluções e compartilhar eventuais experiências que eles já possam ter com os tópicos a serem abordados na aula. Também é um momento de engajá-los no tema da aula.



Tempo previsto: 8 minutos.



Gestão de sala de aula:

- Assegure que todos os estudantes tenham a oportunidade de participar. Se necessário, faça um rodízio ou direcione perguntas a estudantes que estejam menos ativos, para garantir a participação de todos.
- Mantenha um ambiente de respeito, em que todas as opiniões sejam valorizadas, garantindo que todos se sintam confortáveis para expressar seus pontos de vista.
- Conclua a atividade resumindo as principais ideias discutidas e vinculando-as aos objetivos de aprendizagem da aula.



Condução da dinâmica: apesar do conceito ser apresentado durante a aula, comente, ao final, que:

- **Generalização é mais importante que memorizar detalhes específicos**

Assim como no estudo, em que **entender os conceitos** é mais útil do que decorar respostas específicas, nos modelos de *machine learning*, queremos que eles aprendam o padrão geral dos dados, para que ele possa funcionar bem com novos exemplos.

- **O equilíbrio é a chave**

Uma estratégia equilibrada envolve estudar tanto exemplos específicos quanto conceitos mais amplos, para se sair bem em diferentes situações. Da mesma forma, modelos de *machine learning* precisam ser balanceados para que consigam se adaptar bem a novos dados e não apenas aos dados antigos.

- **Evitar o *overfitting* na vida real**

Assim como decorar as respostas da prova do ano passado pode não ajudar na prova atual, tentar aprender todos os detalhes de uma situação específica pode nos deixar despreparados para outras. É importante sempre buscar entender o contexto geral e estar preparado para novas situações.



Expectativas de respostas: os estudantes provavelmente irão perceber que:

Estudar só as perguntas da prova passada é ruim

1. Embora eles possam acertar perguntas parecidas, não estarão preparados para novos tipos de perguntas.
2. Isso pode fazer com que eles se saiam mal em provas diferentes, já que não estudaram o conceito de forma geral.

Relacionamento com o *overfitting*

1. Assim como no exemplo da prova, o ***overfitting*** é quando um modelo de aprendizado se ajusta demais aos dados antigos, mas falha ao ser aplicado a novos dados, porque ficou "viciado" nos detalhes específicos do passado.

Slide 8



Orientações: a seção **Colocando em prática** tem como objetivo aplicar os conhecimentos construídos durante a aula incentivando os estudantes a pensar criticamente e de forma prática.



Tempo previsto: 32 minutos.



Gestão de sala de aula

Organização do espaço: divida os estudantes em grupos. Cada grupo trabalha em uma estação (computador). Nomeie cada estação de trabalho com um número ou letra para fácil referência.

Estação de revisão: designar uma "Estação de revisão" (pode ser um quadro branco ou um espaço em que você, como professor, ficará disponível). Alunos que terminarem a tarefa mais cedo ou que precisarem de ajuda devem ir à Estação de revisão para apresentar seu progresso ou discutir dificuldades.

Autonomia e colaboração: incentive os alunos a tentar resolver problemas entre seus pares antes de pedir ajuda. Isso fortalece a colaboração e a capacidade de resolução de problemas. Alunos que resolvem um problema de forma eficiente podem ser incentivados a ajudar outros grupos.

Rotina de verificação: realize verificações periódicas, caminhando pelo laboratório para observar o progresso dos grupos, oferecendo dicas ou ajustando o foco, se necessário.

Revisão e reflexão: no final da sessão, reserve alguns minutos para uma revisão em grupo. Peça a alguns grupos para compartilharem soluções ou discutirem desafios enfrentados. Use essa oportunidade para reforçar boas práticas de programação, comportamento em laboratório e revisão de conceitos. Oriente os alunos a criarem uma folha com os assuntos/fórmulas/códigos mais importantes da aula (peça para preencherem aula a aula).



Condução da dinâmica

Passo 1: apresente o conceito principal de forma concisa, usando linguagem e exemplos simples e relevantes. Permita que sejam feitas algumas perguntas rápidas para garantir a compreensão antes de seguir adiante.

Passo 2: demonstre os exemplos juntamente com os alunos, permitindo que eles acompanhem e copiem o código. Caso prefira, forneça o código para que eles possam executá-lo em seus computadores. Garanta que todos estejam no mesmo ritmo, esclarecendo dúvidas ao longo do processo. Na maioria das vezes não é necessário explicar cada linha de código e sim focar o assunto da aula.

Passo 3: leia a tarefa e oriente os grupos a começar a atividade, que deve ser realizada no Jupyter Notebook ou em uma ferramenta similar. Durante o exercício, circule entre os grupos para assegurar que todos estejam focados e dentro do tempo estabelecido. Incentive que cada grupo compartilhe um ponto chave de sua discussão, mesmo que a atividade não esteja completa. Facilite uma troca rápida de ideias entre os grupos. Ao final, reforce os conceitos explorados, mostre o código durante a prática e conclua com uma recapitulação, caso todos tenham finalizado.



Expectativa de resposta: os fatores são a complexidade do modelo, quantidade de dados, falta de uso de regularização e muitas épocas de treinamento.

Slide 9



Orientações: o *overfitting* ocorre quando um modelo de *machine learning* aprende não apenas os padrões relevantes dos dados de treinamento, mas também os ruídos e os detalhes irrelevantes, resultando em um desempenho fraco ao generalizar para novos dados. As principais causas de *overfitting* são:

- **Modelo muito complexo:** quando um modelo tem muitas camadas, neurônios, ou graus de liberdade (como em redes neurais profundas), ele pode se ajustar excessivamente aos dados de treinamento, capturando até mesmo ruídos e variações insignificantes. Modelos altamente complexos conseguem "memorizar" os dados em vez de aprender padrões generalizáveis.
- **Quantidade insuficiente de dados:** com poucos dados de treinamento, o modelo pode facilmente sobreajustar, já que a variabilidade nos dados disponíveis não é suficiente para representar adequadamente a distribuição real do problema. Isso aumenta a chance de o modelo se ajustar aos detalhes específicos dos dados de treinamento.
- **Treinamento por muitas épocas:** se um modelo é treinado por muitas iterações sem interrupção (por exemplo, sem o uso de *early stopping*), ele pode acabar aprendendo padrões que são exclusivos dos dados de treinamento e que não generalizam bem para novos dados.
- **Ausência de técnicas de regularização:** a regularização (como L1, L2 ou *dropout*) atua como um mecanismo de controle de complexidade, penalizando pesos excessivos ou desativando neurônios aleatoriamente durante o treinamento. A falta dessas técnicas permite que o modelo se ajuste demais aos dados de treinamento.
- **Desequilíbrio nos dados:** se o conjunto de dados de treinamento tem um desequilíbrio entre as classes (ou características), o modelo pode ajustar-se demais às classes majoritárias e, portanto, não generalizar corretamente para dados de teste com classes minoritárias ou sub-representadas.
- **Ausência de validação cruzada:** a falta de uso de validação cruzada durante o treinamento pode resultar em um modelo que performa bem nos dados de treinamento, mas que falha ao ser testado em dados não vistos.

Slide 10



Orientações: o impacto do *overfitting* no desempenho dos modelos pode ser significativo, afetando diretamente sua capacidade de generalização. Os principais efeitos são:

- **Baixo desempenho em novos dados** – O modelo tem um desempenho excelente nos dados de treinamento, mas falha em generalizar para dados novos ou de teste, resultando em baixa acurácia ou erro elevado nesses cenários.
- **Aumento da variância** – O *overfitting* faz com que o modelo seja sensível a pequenas variações nos dados, tornando-o altamente instável e com alta variância. Pequenos ruídos podem causar mudanças drásticas nas previsões.
- **Modelo não confiável** – Modelos em *overfitting* são pouco confiáveis em ambientes de produção, pois não conseguem lidar bem com dados que não seguem exatamente o padrão dos dados de treinamento.

Professor, é importante reforçar com os alunos que *overfitting* é o mesmo que sobreajuste no que se refere a Redes Neurais.

Slide 13



Seção Pause e resposta

Tempo previsto: 3 minutos.



Pergunta: qual dos seguintes fatores pode causar *overfitting* em um modelo?

Resposta correta: modelo treinado por muitas épocas sem interrupção.

Feedback: ao treinar o modelo por muitas épocas sem interrupção, ele começa a aprender padrões irrelevantes e específicos dos dados de treinamento.

Slide 15



Seção Pause e resposta

Tempo previsto: 3 minutos.



Pergunta: qual é o impacto do *overfitting* no desempenho do modelo?

Resposta correta: aumento da variância, torna-se instável e muda com pequenos ruídos nos dados.

Feedback: o ***overfitting*** faz com que o modelo se ajuste excessivamente aos dados de treinamento, tornando-o sensível a pequenas variações e ruídos, o que aumenta a variância e faz o modelo se tornar instável quando exposto a novos dados.

Slide 17



Orientações: a seção **O que nós aprendemos hoje?** tem o objetivo de reforçar e esclarecer os conceitos principais discutidos na aula. Essa revisão pode ser uma ferramenta de avaliação informal do aprendizado dos estudantes, identificando áreas que podem precisar de mais atenção em aulas futuras.



Tempo previsto: 2 minutos.



Gestão de sala de aula:

- Mantenha um tom positivo e construtivo, reforçando o aprendizado em vez de focar em correções.
- Seja direto e objetivo nas explicações para manter a atividade dentro do tempo estipulado.
- Engaje os estudantes rapidamente, pedindo confirmações ou reações breves às definições apresentadas.



Condução da dinâmica:

- Explique que esta parte da seção, “Então ficamos assim...”, é um momento de reflexão e esclarecimento sobre os conceitos abordados na aula.
- Informe que será uma rápida revisão para assegurar que o entendimento dos estudantes está alinhado com as definições corretas dos conceitos.
- Apresente o slide com a definição sintética de cada conceito principal discutido na aula, ampliando em forma de frases completas.
- Finalize resumindo os pontos principais e reiterando a importância de cada conceito e como ele se encaixa no contexto maior da aula.
- Reforce a ideia de que essa revisão ajuda a solidificar o entendimento dos estudantes e prepará-los para aplicar esses conceitos em situações práticas.



Expectativas de respostas:

Os estudantes devem sair da aula com um entendimento claro e preciso dos conceitos principais.

A atividade serve como uma verificação rápida do entendimento dos estudantes e uma oportunidade para corrigir quaisquer mal-entendidos.

Educação Profissional Paulista

Técnico em
**Ciência de
Dados**