

**Educação
Profissional
Paulista**

Técnico em
**Ciência de
Dados**



**GOVERNO DO ESTADO
DE SÃO PAULO**

Processamento de linguagem natural

Processamento de linguagem natural (NLP)

Introdução a processamento de linguagem natural (NLP)

Código da aula: [DADOS]ANO2C4B2S13A1



GOVERNO DO ESTADO
DE SÃO PAULO

Processamento de
linguagem natural

Mapa da Unidade 2 Componente 4

Modelos de linguagem
(Parte 1)

semana
15

Modelos de linguagem
(Parte 2)

semana
16

semana
12

Análise sintática
e semântica

semana
13

Você está aqui!

Processamento de
linguagem natural (NLP)

semana
17

Entidades
nomeadas e
reconhecimento
de entidades

Processamento de
linguagem natural

Mapa da
Unidade 2
Componente 4

Você está aqui!

Processamento de
linguagem natural (NLP)

Aula 1

Código da aula: [DADOS]ANO2C4B2S13A1

13



Objetivos da aula

- Identificar os conceitos básicos e a importância do NLP.



Recursos didáticos

- Acesso ao laboratório de informática e/ou à internet;
- Software Anaconda/Jupyter Notebook instalado ou similar.



Duração da aula

50 minutos.



Habilidades técnicas

- Aplicar os conceitos básicos de processamento de linguagem natural.




Habilidades socioemocionais

- Demonstrar interesse e curiosidade pelo conceito de processamento de linguagem natural.

Ponto de
partida

Classificação de transações



© Getty Images

Imagine que você está acompanhando suas transações de cartão de crédito e deseja entender melhor como cada uma se encaixa nas suas despesas diárias.

Para isso, ao visualizar uma transação, como "Compra no supermercado A" ou "Pagamento de conta de luz," você gostaria de categorizá-la automaticamente em "Supermercado" ou "Serviços", entre outras categorias possíveis.

Você considera possível classificar automaticamente essas transações em categorias específicas, analisando apenas o texto de cada uma?

Colocando
em **prática**

Conceito de processamento de linguagem natural (NLP)

- ▶ Subcampo da inteligência artificial que busca a interação entre máquinas e linguagem humana.
- ▶ Permite que máquinas processem e entendam textos e falas.
- ▶ Facilita tarefas como tradução automática, análise de sentimentos, geração de texto, resposta a perguntas, classificação de textos, sumarização de conteúdo e criação de chatbots.

Colocando
em **prática**

Histórico do NLP

1

1960

Joseph Weizenbaum desenvolve o ELIZA, um dos primeiros programas de processamento de linguagem natural, capaz de simular conversas simples.

2

1970

Introdução das gramáticas livres de contexto e regras formais para análise sintática, estabelecendo bases para análise linguística automatizada.

3

1980

Início do uso de modelos probabilísticos para NLP, como o modelo de n-gramas, que calcula probabilidades de sequências de palavras.

4

1990

Avanço dos modelos de Markov oculto (HMM) e da modelagem estatística de linguagens para tarefas como reconhecimento de fala e etiquetagem de partes do discurso (POS tagging).

Colocando
em **prática**

Histórico do NLP

5

Década de 2000

Adoção de word embeddings, como word2vec, para representar palavras em vetores, melhorando a semântica e a compreensão de contexto.


6

2018

Introdução de transformers, como BERT e GPT, revolucionando o NLP com capacidade de entender contexto profundo e produzir texto coerente.

Colocando
em **prática**

Analizando transações financeiras



Materiais necessários

- Acesso ao laboratório de informática e/ou à internet.



Passo a passo


1. Acessem o roteiro de atividade prática;
2. Analisem o enunciado e os dados apresentados no roteiro;
3. Realizem a tarefa proposta.



30 minutos



**Grupo
(2 a 3 pessoas)**



Baixe o roteiro dessa atividade



Pause e
responda

Qual é o objetivo principal do processamento de linguagem natural (NLP)?

Reproduzir sons da
linguagem humana

Facilitar a comunicação
entre máquinas e humanos

Traduzir todos os textos
para inglês

Criar imagens a partir
de texto



Pause e
responda

Qual é o objetivo principal do processamento de linguagem natural (NLP)?



Reproduzir sons da
linguagem humana

Facilitar a comunicação
entre máquinas e humanos



Traduzir todos os textos
para inglês

Criar imagens a partir
de texto





Pause e
responda

Em 2018, quais modelos revolucionaram o NLP ao permitir que sistemas compreendessem contextos mais profundos?

ELIZA e word2vec

HMM e N-gramas

BERT e GPT

Transformadores e
word embeddings



Pause e
responda

**Em 2018, quais modelos revolucionaram o NLP
ao permitir que sistemas compreendessem
contextos mais profundos?**



ELIZA e word2vec

HMM e N-gramas



BERT e GPT

Transformadores e
word embeddings





© Getty Images

O que nós
aprendemos
hoje?

Então ficamos assim...

- 1** O NLP permite que máquinas compreendam e interpretem a linguagem humana, facilitando tarefas como tradução e análise de sentimentos.
- 2** Na década de 2000, os word embeddings, como o word2vec, trouxeram avanços significativos na compreensão de contexto.
- 3** Em 2018, transformers, como BERT e GPT, revolucionaram o NLP ao permitir uma compreensão profunda e geração de texto.

Saiba mais

Que tal entender como o NLP está revolucionando a comunicação entre humanos e máquinas?

Confira este guia completo com conceitos e técnicas essenciais para dominar essa tecnologia incrível!

PREMEBIDA, S. M. Guia de NLP: conceitos e técnicas. **Alura**, 25 nov. 2021. Disponível em: <https://www.alura.com.br/artigos/guia-nlp-conceitos-tecnicas>. Acesso em: 21 jan. 2025.

Referências da aula

Identidade visual: Imagens © Getty Images

BIRD, S.; KLEIN, E.; LOPER, E. **Natural language processing with Python**. [S.l.]: O'Reilly Media, 2009.

GÉRON, A. **Mãos à obra**: aprendizado de máquina com Scikit-Learn, Keras e TensorFlow: conceitos, ferramentas e técnicas para a construção de sistemas inteligentes. Rio de Janeiro: Alta Books, 2021.

GRUS, J. **Data Science do zero**: noções fundamentais com Python. Rio de Janeiro: Alta Books, 2021.

JURAFSKY, D.; MARTIN, J. H. **Speech and language processing**. [S.l.]: Pearson, 2013.

Orientações ao professor

Slide 6



Orientações: Professor, a **seção Ponto de partida** aparece no início de cada aula e tem como objetivo ativar o conhecimento prévio dos estudantes sobre o tema da aula e estimular seu pensamento crítico e suas habilidades comunicativas. Por meio de uma situação-problema ou exemplo próximo da realidade do estudante, pretende-se sair da abstração conceitual e promover um diálogo dinâmico para explorar hipóteses, soluções e compartilhar eventuais experiências que os estudantes já possam ter com os tópicos a serem abordados na aula. É também um momento de engajá-los em relação ao tema da aula.



Tempo previsto: 8 minutos.



Gestão de sala de aula: assegure que todos os estudantes tenham a oportunidade de participar. Se necessário, faça rodízio ou direcione perguntas a estudantes que estejam menos ativos para garantir a participação de todos. Mantenha um ambiente de respeito, onde todas as opiniões são valorizadas, garantindo que todos se sintam confortáveis para expressar seus pontos de vista. Conclua a atividade resumindo as principais ideias discutidas e vinculando-as aos objetivos de aprendizagem da aula.



Condução da dinâmica:

Professor, apesar do conceito ser apresentado durante a aula, comente ao final que:

- Processamento de linguagem natural permite que máquinas processem e entendam textos e falas.
- Facilita tarefas, como classificação de textos.



Expectativas de respostas:

Os estudantes provavelmente perceberão que:

- Seria possível utilizar Processamento de linguagem natural para classificar as transações financeiras automaticamente.

Slides 7 e 10



Orientações: Professor, a **seção Colocando em prática** tem como objetivo aplicar os conhecimentos construídos durante a aula, incentivando os estudantes a pensar criticamente e de forma prática.



Tempo previsto: 32 minutos.



Gestão de sala de aula:

Organização do espaço: organize os estudantes em grupos de 2 ou 3. Cada grupo trabalha em uma estação (computador). Nomeie cada estação de trabalho com um número ou letra para fácil referência.

Estação de revisão: designar uma “estação de revisão” (pode ser um quadro branco ou um espaço onde você, como professor, fica disponível). Os estudantes que terminam a tarefa mais cedo, ou que precisam de ajuda, devem ir até a estação de revisão para apresentar seu progresso ou discutir dificuldades.

Autonomia e colaboração: incentive os estudantes a tentar resolver problemas primeiro entre seus pares, antes de pedir ajuda. Isso fortalece a colaboração e a capacidade de resolução de problemas. Estudantes que resolvem um problema de forma eficiente podem ser incentivados a ajudar outros grupos.

Rotina de verificação: faça verificações periódicas, caminhando pelo laboratório, para observar o progresso dos grupos, oferecendo dicas ou ajustando o foco, se necessário.

Revisão e reflexão: no final da seção, reserve alguns minutos para uma revisão em grupo. Peça a alguns grupos que compartilhem soluções ou discutam desafios enfrentados. Use essa oportunidade para reforçar boas práticas de programação, comportamento em laboratório e revisão de conceitos. Oriente os estudantes a criar uma folha com os assuntos/fórmulas/códigos mais importantes da aula (peça que vão preenchendo aula a aula).



Condução da dinâmica:

Passo 1: apresente o conceito principal de forma concisa, usando linguagem e exemplos simples e relevantes. Permita algumas perguntas rápidas para garantir a compreensão, antes de seguir adiante.

Passo 2: leia a tarefa e oriente os grupos a começarem a atividade, que deve ser realizada utilizando o roteiro. Durante o exercício, circule entre os grupos para assegurar que todos estejam focados e dentro do tempo estabelecido. Incentive cada grupo a compartilhar um ponto-chave de sua discussão, mesmo que a atividade não esteja completa. Facilite uma troca rápida de ideias entre os grupos. Ao final, reforce os conceitos explorados, conclua com uma recapitulação, caso todos tenham finalizado.

Passo 3: após os estudantes finalizarem o preenchimento das categorias das transações, peça a eles que apresentem as categorias atribuídas e qual o padrão que eles identificaram para atribuir uma categoria ao invés de outra. Caso algum grupo tenha atribuído uma categoria diferente do outro, peça que expliquem o que levou à atribuição. Lembre-se de que é importante sempre focar no padrão de escrita da transação, e um grupo pode interpretar de forma diferente do outro o que a transação representa, o que de fato pode acontecer no processamento de linguagem natural.



Expectativas de respostas: classificação das transações na tabela com preenchimento da coluna Categoria, conforme o exemplo da transação de número 1:

Pagamento de conta de luz – Serviços
Transferência recebida – Transferência
Assinatura mensal video Nnn – Entretenimento

Continua

Slides 7 e 10



Expectativas de respostas:

Jantar no restaurante italiano – Restaurante
Compra de gasolina no posto Sss – Combustível
Pagamento de aluguel – Moradia
Compra de roupas na loja Zzz – Vestuário
Compra de eletrônicos no Mmm – Eletrônicos
Compra de livros na Aaa – Livros
Compra de remédios na farmácia – Farmácia
Pagamento de fatura do cartão – Financeiro
Compra de móveis para casa – Móveis/Casa
Assinatura de música Sss – Entretenimento
Transferência enviada para João – Transferência

Slide 9



Orientações: Professor, se quiser, pode adicionar essas informações em sala de aula:

1. **2020 em diante:** expansão do uso de modelos de linguagem de grande escala (large language models - LLMs), como GPT-3 e BERT evoluídos, possibilitando aplicações em áreas como atendimento ao cliente, criação de conteúdo e auxílio em pesquisas científicas.
2. **Avanços em eficiência:** modelos como BERT e GPT são otimizados para serem mais leves, acessíveis e utilizáveis em dispositivos com recursos limitados.
3. **Foco na ética e fairness:** discussões sobre viés algorítmico, privacidade e transparência em modelos de NLP ganharam relevância, promovendo a criação de sistemas mais justos e explicáveis.

Para curiosidade:

- **Modelos Baseados no GPT (autoregressivos).** Seguem a abordagem do GPT, usando uma arquitetura unidirecional para prever a próxima palavra em uma sequência:

1. GPT (OpenAI, 2018)
 - GPT-2 (2019) / GPT-3 (2020) / GPT-4 (2023)
2. Claude (Anthropic, 2023)
 - Inspirado no GPT, com foco em alinhamento ético e segurança.
3. OPT (Meta, 2022)
 - Replica princípios do GPT-3, projetado para transparência e eficiência.
4. LLaMA (Meta, 2023)
 - Inspirado no GPT, mas otimizado para eficiência em ambientes de pesquisa.
5. Gopher (DeepMind, 2021)
 - Similar ao GPT, com foco em interpretação e precisão científica.
6. Chinchilla (DeepMind, 2022)
 - Segue o modelo Gopher, mas otimiza o número de parâmetros em relação aos dados de treinamento.
7. PaLM (Google, 2022)
 - Grande modelo com 540 bilhões de parâmetros, inspirado no GPT para tarefas complexas.
8. Bloom (BigScience, 2022)
 - Semelhante ao GPT, mas com foco em multilinguismo e acessibilidade como código aberto.

- **Modelos Baseados no BERT (Bidirecionais):** estes modelos focam na compreensão do contexto completo do texto, analisando palavras em ambas as direções:

1. BERT (Google, 2018)
 - Introduziu o conceito de treinamento bidirecional para tarefas de compreensão.
2. RoBERTa (Facebook, 2019)
 - Variante mais robusta e eficiente do BERT.
3. DistilBERT (Hugging Face, 2019)
 - Versão compacta do BERT, com menor custo computacional.
4. ALBERT (Google, 2019)
 - Variante do BERT com menos parâmetros, mas igualmente eficiente.
5. ERNIE (Baidu, 2019–2023)
 - Modelo baseado no BERT, otimizado para o idioma chinês e tarefas locais.

Continua ...

Slide 9



Orientações:

- **Modelos Híbridos (GPT + BERT ou outros):** esses modelos combinam características de GPT (geração) e BERT (compreensão) ou inovam em direção à eficiência:

1.T5 (Google, 2020)

- Transformador unificado de texto para texto, utilizado tanto para compreensão quanto geração de texto.

2.XLNet (Google & CMU, 2019)

- Combina bidirecionalidade (BERT) com autorregressão (GPT), oferecendo o melhor dos dois mundos.

3.Flan-T5 (Google, 2022)

- Variante aprimorada do T5, projetada para tarefas multitarefas com treinamento mais eficiente.

4.Fusion-in-Decoder (DeepMind, 2022)

- Modelo que mistura as capacidades do GPT para geração com o poder de compreensão do BERT.

Fonte:

BROCKMAN, G. et al. **OpenAI API**, 11 jun. 2020. Disponível em: <https://openai.com/index/openai-api/>. Acesso em: 22 jan. 2025.

CHOWDHURY, A. et al. PaLM: scaling language modeling with pathways. **Journal of Machine Learning Research**, v. 24, p. 1-113, 2023. Disponível em:

<https://www.jmlr.org/papers/volume24/22-1144/22-1144.pdf>. Acesso em: 22 jan. 2025.

DEVLIN, J. et al. **BERT**: Pre-training of deep bidirectional transformers for language understanding. NAACL-HLT, Minnessota, p. 4171-4186, 2-7 jun. 2019. Disponível em:

<https://aclanthology.org/N19-1423.pdf>. Acesso em: 21 jan. 2025.

OPENAI. **GPT-2: 1.5B release**. 5 nov. 2019. Disponível em: <https://openai.com/index/gpt-2-1-5b-release/>. Acesso em: 29 jan. 2025

OPENAI. GPT-4 Technical Report. **Cornell University/arXiv**, 4 mar. 2024. Disponível em: <https://arxiv.org/abs/2303.08774>. Acesso em: 21 jan. 2025.

RADFORD, A. et al. Improving language understanding by generative pre-training. **OpenAI**, 2018. Disponível em: https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf. Acesso em: 22 jan. 2025.

RAFFEL, C. et al. Exploring the limits of transfer learning with a unified text-to-text transformer. **Journal of Machine Learning Research**, v. 21, p. 1-67, 2020. Disponível em:

<https://jmlr.org/papers/volume21/20-074/20-074.pdf>. Acesso em: 21 jan. 2025.

TOUVRON, H. et al. Llama 2: open foundation and fine-tuned chat models. **Cornell University/arXiv**, 19 jul. 2023. Disponível em: <https://arxiv.org/abs/2307.09288>. Acesso em: 21 jan. 2025.

TOUVRON, H. et al. LLaMA: open and efficient foundation language models. **Cornell University/arXiv**, 27 fev. 2023. Disponível em: <https://arxiv.org/abs/2302.13971>. Acesso em: 21 jan. 2025.

YANG, Z. et al. XLNet: Generalized autoregressive pretraining for language understanding. **33rd Conference on Neural Information Processing Systems**, Vancouver, Canada, 8-14 dec. 2019. Disponível em: https://proceedings.neurips.cc/paper_files/paper/2019/file/dc6a7e655d7e5840e66733e9ee67cc69-Paper.pdf. Acesso em: 22 jan. 2025.

Slide 11



Seção Pause e resposta

Tempo: 3 minutos.



Pergunta:

Qual é o objetivo principal do processamento de linguagem natural (NLP)?

Resposta correta:

Facilitar a comunicação entre máquinas e humanos.

Feedback:

O NLP visa facilitar a interação entre máquinas e linguagem humana, permitindo que elas entendam e processem textos e falas.

Slide 13



Seção Pause e resposta

Tempo: 3 minutos.



Pergunta:

Em 2018, quais modelos revolucionaram o NLP ao permitir que sistemas compreendessem contextos mais profundos?

Resposta correta:

BERT e GPT

Feedback:

Em 2018, os modelos BERT e GPT, baseados na arquitetura transformer, revolucionaram o NLP ao possibilitar uma compreensão mais profunda do contexto.

Slide 15



Orientações: Professor, **a seção O que nós aprendemos hoje?** tem o objetivo de reforçar e esclarecer os conceitos principais discutidos na aula. Essa dinâmica pode ser uma ferramenta de avaliação informal do aprendizado dos estudantes, identificando áreas que podem precisar de mais atenção em aulas futuras.



Tempo previsto: 3 minutos.



Gestão de sala de aula:

Mantenha um tom positivo e construtivo, reforçando o aprendizado em vez de focar em correções.

Seja direto e objetivo nas explicações para manter a atividade dentro do tempo estipulado.

Engaje os estudantes rapidamente, pedindo confirmações ou reações breves às definições apresentadas.



Condução da dinâmica: 2 minutos.

Explique que esta parte da seção, **“Então ficamos assim...”**, é um momento de reflexão e esclarecimento sobre os conceitos abordados na aula.

Informe que será uma rápida revisão para assegurar que os entendimentos dos estudantes estão alinhados com as definições corretas dos conceitos.

Apresente o slide com a definição sintética de cada conceito principal discutido na aula, ampliando em forma de frases completas.

Para cada conceito, faça uma breve comparação com as palavras-chave citadas pelos estudantes na dinâmica de nuvem de palavras.

Destaque se as contribuições dos estudantes estavam alinhadas com o conceito e ofereça esclarecimentos rápidos, caso haja discrepâncias ou mal-entendidos.

Finalize resumindo os pontos principais e reiterando a importância de cada conceito e como ele se encaixa no contexto maior da aula.

Reforce a ideia de que essa revisão ajuda a solidificar o entendimento dos estudantes e prepará-los para aplicar esses conceitos em situações práticas.



Expectativas de respostas:

Os estudantes devem sair da aula com um entendimento claro e preciso sobre os conceitos principais.

A atividade serve como uma verificação rápida do entendimento dos estudantes e uma oportunidade para corrigir quaisquer mal-entendidos.

**Educação
Profissional
Paulista**

Técnico em
**Ciência de
Dados**



**GOVERNO DO ESTADO
DE SÃO PAULO**