

**Educação
Profissional
Paulista**

Técnico em
**Ciência de
Dados**



**GOVERNO DO ESTADO
DE SÃO PAULO**

Processamento de linguagem natural

Processamento de linguagem natural (NLP)

Processamento de linguagem natural (NLP)

Código da aula: [DADOS]ANO2C4B2S13A2



Processamento de
linguagem natural

Mapa da Unidade 2 Componente 4

Modelos de linguagem
(Parte 1)

semana
15

Modelos de linguagem
(Parte 2)

semana
16

semana
12

Análise sintática
e semântica


semana
13

Você está aqui!

Processamento de
linguagem natural (NLP)

semana
17

Entidades
nomeadas e
reconhecimento
de entidades



Processamento de
linguagem natural

Mapa da
Unidade 2
Componente 4

Você está aqui!

Processamento de
linguagem natural (NLP)

Aula 2

Código da aula: [DADOS]ANO2C4B2S13A2

13



Objetivos da aula

- Identificar técnicas práticas e aplicações do NLP.



Recursos didáticos

- Acesso ao laboratório de informática e/ou à internet;
- Software Anaconda/Jupyter Notebook instalado ou similar.



Duração da aula

50 minutos.



Habilidades técnicas

- Aplicar os conceitos básicos de processamento de linguagem natural.



Habilidades socioemocionais

- Demonstrar interesse e curiosidade pelo conceito de processamento de linguagem natural.

Colocando
em **prática**

Técnicas básicas de NLP

	descricao	tokens
0	compra no supermercado eee	[compra, no, supermercado, eee]
1	pagamento de conta de luz	[pagamento, de, conta, de, luz]
2	transferência recebida	[transferência, recebida]
3	assinatura mensal streaming nnn	[assinatura, mensal, streaming, nnn]
4	jantar no restaurante italiano	[jantar, no, restaurante, italiano]
5	compra de gasolina no posto sss	[compra, de, gasolina, no, posto, sss]

Produzido pela SEDUC-SP com a ferramenta Jupyter Notebook.

Tokenização

Processo de dividir uma frase em partes menores chamadas tokens. Essencial para tarefas como classificação, tradução automática e análise de sentimentos.

Benefícios:

- Remove pontuações e caracteres especiais.
- Simplifica o texto para as próximas etapas de análise.

Colocando em **prática**

Técnicas básicas de NLP

	tokens	tokens_sem_stopwords
0	[compra, no, supermercado, eee]	[compra, supermercado, eee]
1	[pagamento, de, conta, de, luz]	[pagamento, conta, luz]
2	[transferência, recebida]	[transferência, recebida]
3	[assinatura, mensal, streaming, nnn]	[assinatura, mensal, streaming, nnn]
4	[jantar, no, restaurante, italiano]	[jantar, restaurante, italiano]
5	[compra, de, gasolina, no, posto, sss]	[compra, gasolina, posto, sss]

Produzido pela SEDUC-SP com a ferramenta Jupyter Notebook.

Stopwords

Palavras comuns que não acrescentam valor ao modelo, como "o", "de" e "que". Geralmente são conectivos ou artigos frequentes em textos.

Por que remover stopwords?

- ▶ Reduz o ruído nos dados, tornando o texto mais relevante para análise.
- ▶ Melhora a eficiência do processamento, otimizando algoritmos e reduzindo o custo computacional.

Colocando
em **prática**

Técnicas básicas de NLP

	assinatura	compra	streaming	supermercado	pagamento	transferência
0	0	1	0	1	0	0
1	0	0	0	0	1	0
2	0	0	0	0	0	1
3	1	0	1	0	0	0
4	0	0	0	0	0	0
5	0	1	0	0	0	0

Produzido pela SEDUC-SP com a ferramenta Jupyter Notebook.

Bag of words

Técnica para transformar texto em dados numéricos. Representa o texto pela frequência de cada palavra, ignorando a ordem.

Benefícios:

- ▶ Permite que algoritmos interpretem textos de maneira numérica, facilitando a aplicação de métodos estatísticos ou de aprendizado de máquina.
- ▶ Amplamente usada em tarefas como classificação, análise de sentimentos e detecção de spam.

Colocando em **prática**

Técnicas básicas de NLP

	tokens_sem_stopwords	tokens_stemmed
0	[compra, supermercado, eee]	[compr, supermerc, eee]
1	[pagamento, conta, luz]	[pag, cont, luz]
2	[transferência, recebida]	[transfer, receb]
3	[assinatura, mensal, streaming, nnn]	[assinat, mens, streaming, nnn]
4	[jantar, restaurante, italiano]	[jant, restaurant, itali]
5	[compra, gasolina, posto, sss]	[compr, gasolin, post, ss]

Produzido pela SEDUC-SP com a ferramenta Jupyter Notebook.

Stemming

Reduz palavras à sua raiz, removendo sufixos e variações.

Características:

- ▶ É um método rápido, mas pode ser impreciso, pois reduz as palavras sem considerar o contexto.
- ▶ Útil em cenários onde a precisão semântica não é tão crítica, como em recuperação de informações ou análise de documentos grandes.

Colocando
em **prática**

Técnicas básicas de NLP

	tokens_sem_stopwords	tokens_stemmed
0	[compra, supermercado, eee]	[compr, supermerc, eee]
1	[pagamento, conta, luz]	[pag, cont, luz]
2	[transferência, recebida]	[transfer, receb]
3	[assinatura, mensal, streaming, nnn]	[assinat, mens, streaming, nnn]
4	[jantar, restaurante, italiano]	[jant, restaurant, itali]
5	[compra, gasolina, posto, sss]	[compr, gasolin, post, ss]

Produzido pela SEDUC-SP com a ferramenta Jupyter Notebook.

Lematização

Reduz palavras à sua forma base, considerando o contexto.

Mantém o significado da palavra.

Aplicações:

- Ideal para tarefas como busca de informações, análise semântica e tradução automática, onde o significado e o contexto são críticos.

Colocando
em **prática**

Modelos de linguagem

Compreensão de contexto

Estruturas capazes de captar o contexto das palavras em uma frase, permitindo uma compreensão mais profunda do significado e intenção das frases.

Identificação de padrões e uso

Ajudam as máquinas a reconhecer padrões de uso das palavras, como a frequência e posição em que aparecem, facilitando uma análise mais rica do texto.

Aplicações em tarefas de NLP

São utilizados em tarefas como tradução automática, análise de sentimentos e sistemas de resposta a perguntas, melhorando a precisão e a relevância das respostas fornecidas pela máquina.

Colocando em **prática**

Embeddings

tokens	embedding
[compra, no, supermercado, eee]	[0.0015915707, 0.027187956, 0.018861547, -0.029643182, -0.002581229]
[pagamento, de, conta, de, luz]	[-0.008819209, 0.009545991, 0.0897994, 0.0983115, 0.02191205]
[transferência, recebida]	[-0.13677523, 0.0017858185, 0.15582922, -0.101616696, -0.08505298]
[assinatura, mensal, streaming, nnn]	[0.025455898, 0.06973927, 0.045268, -0.11063005, -0.030308908]
[jantar, no, restaurante, italiano]	[0.06725187, -0.007623378, -0.05482669, 0.05689774, 0.013155572]
[compra, de, gasolina, no, posto, sss]	[-0.05093654, 0.07140412, 0.006726773, 0.04261655, -0.019388327]

Produzido pela SEDUC-SP com a ferramenta Jupyter Notebook.

- Representações vetoriais que mapeiam palavras em um espaço numérico.
- Capturam semântica e contexto das palavras.
- Transformam palavras em vetores que refletem relações semânticas e contextuais.

Embeddings

Word2vec

- Desenvolvido pelo Google em 2013.
- Utiliza redes neurais para aprender o contexto das palavras.
- Produz embeddings de alta qualidade, superando a codificação one-hot.

GloVe

- Desenvolvido pela equipe de Stanford em 2014.
- Captura semântica global e local de grandes corpus de texto.
- Útil para análises que requerem contexto amplo e específico.

Colocando
em **prática**


Embeddings

FastText

- Criado pelo Facebook em 2016.
- Incorpora informações de subpalavras (morfologia).
- Melhora o tratamento de palavras novas ou raras, especialmente em línguas com morfologia rica.

Colocando
em **prática**

Processamento de linguagem natural



Materiais necessários

- Acesso ao laboratório de informática e/ou à internet;
- Software Anaconda/Jupyter Notebook instalado ou similar.



Passo a passo


1. Acessem o Roteiro da Atividade Prática;
2. Executem o código que está no material de apoio [DADOS]ANO2C4B2S13A2.ipynb;
3. Realizem a tarefa indicada no roteiro;
4. Respondam às perguntas apresentadas em seguida.



30 minutos



**Grupo
(2 a 3 pessoas)**



Baixe o roteiro dessa atividade



Pause e
responda

Qual técnica de NLP reduz palavras à sua forma base, considerando o contexto?

Lematização

Tokenização

Stemming

Bag of words



Pause e
responda

Qual técnica de NLP reduz palavras à sua forma base, considerando o contexto?



Lematização

Tokenização



Stemming

Bag of words





© Getty Images

O que nós
aprendemos
hoje?

Então ficamos assim...

- 1** As técnicas básicas de NLP incluem a tokenização, que divide textos em partes menores, e a remoção de stopwords, que elimina palavras comuns. Ambas facilitam a análise do texto.
- 2** Bag of words transforma texto em dados numéricos pela frequência das palavras, enquanto stemming e lematização reduzem palavras à sua raiz ou forma base, tornando o texto mais uniforme.
- 3** Modelos de linguagem e embeddings, como word2vec, GloVe e fastText, representam palavras em vetores e capturam o contexto. Esses modelos ajudam a melhorar a compreensão do texto.

Referências da aula

Identidade visual: Imagens © Getty Images

BIRD, S.; KLEIN, E.; LOPER, E. **Natural language processing with Python**. [S.l.]: O'Reilly Media, 2009.

GÉRON, A. **Mãos à obra**: aprendizado de máquina com Scikit-Learn, Keras e TensorFlow: conceitos, ferramentas e técnicas para a construção de sistemas inteligentes. Rio de Janeiro: Alta Books, 2021.

GRUS, J. **Data Science do zero**: noções fundamentais com Python. Rio de Janeiro: Alta Books, 2021.

JURAFSKY, D.; MARTIN, J. H. **Speech and language processing**. [S.l.]: Pearson, 2013.

Orientações ao professor

Slides 6 – 15



Orientações: Professor, a **seção Colocando em prática** tem como objetivo aplicar os conhecimentos construídos durante a aula incentivando os estudantes a pensar criticamente e de forma prática.



Tempo previsto: 42 minutos (ao todo)



Gestão de sala de aula:

Organização do espaço: organize os estudantes em grupos de 2 ou 3. Cada grupo trabalha em uma estação (computador). Nomeie cada estação de trabalho com um número ou letra para fácil referência.

Estação de revisão: designar uma “estação de revisão” (pode ser um quadro branco ou um espaço onde você, como professor, fica disponível). Os estudantes que terminam a tarefa mais cedo ou que precisam de ajuda devem vir à estação de revisão para apresentar seu progresso ou discutir dificuldades.

Autonomia e colaboração: incentive os estudantes a tentar resolver problemas primeiro entre seus pares, antes de pedir ajuda. Isso fortalece a colaboração e a capacidade de resolução de problemas. Estudantes que resolvem um problema de forma eficiente podem ser incentivados a ajudar outros grupos.

Rotina de verificação: faça verificações periódicas, caminhando pelo laboratório, para observar o progresso dos grupos, oferecendo dicas ou ajustando o foco, se necessário.

Revisão e reflexão: no final da seção, reserve alguns minutos para uma revisão em grupo. Peça a alguns grupos que compartilhem soluções ou discutam desafios enfrentados. Use essa oportunidade para reforçar boas práticas de programação, comportamento em laboratório e revisão de conceitos. Oriente os estudantes a criar uma folha com os assuntos/fórmulas/códigos mais importantes da aula (peça que vão preenchendo aula a aula).



Condução da dinâmica:

Passo 1: apresente o conceito principal de forma concisa, utilizando linguagem e exemplos simples e relevantes. Permita algumas perguntas rápidas para garantir a compreensão, antes de seguir adiante.

Passo 2: leia a tarefa e oriente os grupos a começarem a atividade, que deve ser realizada utilizando o roteiro. Durante o exercício, circule entre os grupos para assegurar que todos estejam focados e dentro do tempo estabelecido. Incentive cada grupo a compartilhar um ponto-chave de sua discussão, mesmo que a atividade não esteja completa. Facilite uma troca rápida de ideias entre os grupos. Ao final, reforce os conceitos explorados, conclua com uma recapitulação, caso todos tenham finalizado.



Expectativas de respostas:

Resumo das técnicas apresentadas: indicar as principais técnicas de NLP abordadas, como tokenização, stemming, lematização, análise de sentimento etc.

Demonstração das aplicações: relatar exemplos práticos onde essas técnicas foram aplicadas no notebook, como análise de texto, extração de entidades nomeadas etc.

Insights dos resultados: discussão sobre o que foi observado ao executar as técnicas — como o comportamento dos algoritmos com diferentes tipos de textos ou a eficiência das abordagens.

Slide 16



Seção Pause e resposta

Tempo: 3 minutos.



Pergunta:

Qual técnica de NLP reduz palavras à sua forma base, considerando o contexto?

Resposta correta:

Lematização

Feedback:

A lematização reduz palavras à sua forma base, mantendo o significado e considerando o contexto da palavra na frase.

Slide 18



Orientações: Professor, **a seção O que nós aprendemos hoje?** tem o objetivo de reforçar e esclarecer os conceitos principais discutidos na aula. Essa dinâmica pode ser uma ferramenta de avaliação informal do aprendizado dos estudantes, identificando áreas que podem precisar de mais atenção em aulas futuras.



Tempo previsto: 3 minutos.



Gestão de sala de aula:

Mantenha um tom positivo e construtivo, reforçando o aprendizado em vez de focar em correções.

Seja direto e objetivo nas explicações para manter a atividade dentro do tempo estipulado.

Engaje os estudantes rapidamente, pedindo confirmações ou reações breves às definições apresentadas.



Condução da dinâmica: 2 minutos

Explique que esta parte da seção, **“Então ficamos assim...”**, é um momento de reflexão e esclarecimento sobre os conceitos abordados na aula.

Informe que será uma rápida revisão para assegurar que os entendimentos dos estudantes estão alinhados com as definições corretas dos conceitos.

Apresente o slide com a definição sintética de cada conceito principal discutido na aula, ampliando em forma de frases completas.

Para cada conceito, faça uma breve comparação com as palavras-chave citadas pelos estudantes na dinâmica de nuvem de palavras.

Destaque se as contribuições dos estudantes estavam alinhadas com o conceito e ofereça esclarecimentos rápidos, caso haja discrepâncias ou mal-entendidos.

Finalize resumindo os pontos principais e reiterando a importância de cada conceito e como ele se encaixa no contexto maior da aula.

Reforce a ideia de que essa revisão ajuda a solidificar o entendimento dos estudantes e prepará-los para aplicar esses conceitos em situações práticas.



Expectativas de respostas:

Os estudantes devem sair da aula com um entendimento claro e preciso sobre os conceitos principais.

A atividade serve como uma verificação rápida do entendimento dos estudantes e uma oportunidade para corrigir quaisquer mal-entendidos.

**Educação
Profissional
Paulista**

Técnico em
**Ciência de
Dados**



**GOVERNO DO ESTADO
DE SÃO PAULO**